

GLOBAL AI YAPAY ZEKAYA GİRİŞ BOOTCAMP

Proje Sunumu

Giriş

- **Projenin Amacı:** Bu proje, Fashion MNIST veri setindeki giysi görüntülerini sınıflandırmak için çeşitli makine öğrenimi ve derin öğrenme modellerinin eğitimi ve değerlendirilmesini amaçlamaktadır. Hedef, en iyi performansı elde eden modeli belirlemektir.

Materyal ve Metod

Kullanılan Araçlar ve Kütüphaneler:

- Python
- TensorFlow ve Keras
- Xgboost, LightGBM, Catboost
- Sklearn
- Seaborn, Numpy, Pandas, Matplotlib
- **Yöntem:**
- Veri setinin yüklenmesi ve ön işlenmesi
- Model oluşturma ve eğitme
- Hiperparametre optimizasyonu
- Model değerlendirme ve karşılaştırma

Veri Seti Hakkında Bilgi

- **Fashion MNIST Veri Seti:**
- 28x28 piksel boyutunda gri tonlamalı giysi görüntüleri
- 10 sınıf
 - Eşofman altı
 - Sweatshirt
 - Elbise
 - Ceket
 - Sandalet
 - Çanta
 - Bot
 - Sneaker
 - Gömlek
- Veri seti ikiye ayrılmıştır: eğitim seti ve test seti. Eğitim seti, modeli eğitmek için kullanılırken, test seti modelin performansını değerlendirmek için kullanılır
- Eğitim için 60,000 ve test için 10,000 örnek

Veri Ön İşleme

- Veri ön işleme, makine öğrenimi modellerini eğitmeden önce verileri hazırlama işlemidir.
- Bu projede, aşağıdaki veri ön işleme adımları uygulandı:
 - Verilerin bölünmesi: Veriler X_{train} , y_{train} , X_{test} ve y_{test} olarak bölündü.
 - Eğitim kümesi 60.000, test kümesi ise 10.000 görüntüden oluşmaktadır.
 - Veri boyutları: Veri boyutları yazdırıldı.
 - Görüntü boyutları: Görüntü boyutları yazdırıldı.
 - Yeniden şekillendirme
 - Sampling: Veri seti büyük olduğu için makine öğrenimi metotlarının eğitim süresi ve optimizasyon kısmı uzun sürdüğü için eğitim için 1000 test için 250 görüntü ile çalışıldı
 - Gørselleştirme: 10 rastgele görüntü gørselleştirildi.
 - Normalleştirme: Görüntüler 0 ve 1 arasındaki değerlere ölçeklendirilerek normalize edildi.

Makine Öğrenmesi Algoritmaları

Bu projede, farklı makine öğrenmesi algoritmaları kullanarak modeller eğitilmiştir.

- K-Nearest Neighbors (KNN)
- Destek Vektör Makineleri (SVM)
- Lojistik Regresyon
- Karar Ağacı
- Rastgele Orman(RF)
- Gradient Boosting Machines (GBM)
- LightGBM
- XGBoost
- CatBoost

Derin Öğrenme Algoritmaları

Derin öğrenme algoritmaları, son yıllarda görüntü sınıflandırma gibi karmaşık problemleri çözmek için oldukça etkili hale gelmiştir. Bu algoritmalar, büyük miktarda veriden öğrenerek karmaşık modeller oluşturabilirler.

- Yapay Sinir Ağları (ANN)
- Evrişimli Sinir Ağları (CNN)

Model Eğitimi

Model eğitimi, modelin veri setinden öğrenmesi ve problemleri çözmeyi öğrenmesi için gerekli bir adımdır. Bu aşamada, modelin hiperparametreleri optimize edilir ve model eğitim verileri üzerinde eğitilerek ince ayar yapılır.

- Bazı makine öğrenimi algoritmaları için hiperparametreler optimize edildi.(RF,LightGBM,XGBoost)
- ANN ve CNN de başarıyı artırmak için katman sayısı, noron sayıları, epoch sayısı, düzenlileştirme yöntemleri vs üzerinde oynamalar yapıldı.
- Model eğitim kümesi üzerinde eğitildi.
- Modelin doğruluğu test kümesi üzerinde değerlendirildi.

Değerlendirme Metrikleri

Değerlendirme metrikleri, modelin performansını değerlendirmek için kullanılır. Farklı metrikler farklı yönleri ölçer o yüzden problem farklı metrikler kullanılarak değerlendirildi.

- Accuracy
- Precision
- Recall
- F1 skoru
- Roc-Auc

Sonuçlar

- Makine öğrenimi metotlarında model eğitimi ve hiperparametre optimizasyonu süresi çok uzun sürdüğü için sampling işlemi yapılmıştır. Derin öğrenme ve makine öğrenimi metotlarını kıyaslayabilmek için derin öğrenme metotlarında da sampling işlemi kullanılmıştır.
- Birden fazla değerlendirme metriğiyle (accuracy, precision, recall, f1 vb.) ölçüm yapılmasına rağmen sonuçları karşılaştırmak için accuracy değeri baz alınmıştır.

Makine Öğrenimi Sonuç

- Hiperparametre optimizasyonu öncesi en iyi sonucu veren 3 algoritma şunlardır:
 - 1) LightGBM, Accuracy: 0.8480
 - 2) XGBoost, Accuracy: 0.8360
 - 3) CatBoost, Accuracy: 0.8280
- 3 metota uygulanan hiperparametre optimizasyonu sonrasında elde edilen accuracy sonuçları şu şekildedir.
 - LightGBM, Accuracy: 0.8520
 - XGBoost, Accuracy: 0.8400
 - Random Forest:, Accuracy: 0.8120(öncesinde 0.8080)

Sonuç: Makine öğrenimi metotları arasında accuracy değerine göre en iyi performansı LightGBM göstermiştir.

Derin Öğrenme Sonuç

- Başarıyı artırmadan önce elde ettiğim accuracy ve loss sonuçları:
 - ANN: Test loss: 1.0991, Test accuracy: 0.5560
 - CNN: Test loss: 1.3465, Test accuracy: 0.6000
- Katman sayısı, noron sayıları, epoch sayısı, düzenlileştirme yöntemleri vs üzerinde oynamalar yaparak başarıımı artırma sonrası elde ettiğim sonuçlar:
 - ANN: Test loss: 0.5046 Test accuracy: 0.8320
 - CNN: Test loss: 0.7180, Test accuracy: 0.7120
- Sonuç: Derin öğrenme metotlarından accuracy ve loss değerine göre en iyi performansı ANN göstermiştir.

Tartışma

- Makine öğrenimi metotları arasında en iyi performansı 0.8520 accuracy değeri ile LightGBM göstermiştir.
- Derin öğrenme metotlarından en iyi performansı 0.8320 accuracy değeri ile ANN göstermiştir.
- Her iki değeri kıyasladığımızda en iyi sonucu 0.8520 accuracy değeri ile LightGBM göstermiştir. Daha sonrasında XGBoost 0.8400 accuracy değeri ile performans göstermiştir. XGBoost'tan sonra en iyi performansı ANN 0.8320 accuracy değeri ile göstermiştir. Catboost 0.8280 ve GBM 0.8120 accuracy değeri ile iyi bir performans göstermiştir ancak fit etme süreleri çok uzun sürmektedir.

Öneriler

- Gelecek Çalışmalar:
- - Daha fazla veri ve karmaşık modeller
- - Farklı veri ön işleme teknikleri
- - Diğer derin öğrenme mimarileri ile karşılaştırmalar

Referanslar

- LeCun, Y., Cortes, C., & Burges, C. J. (2010). MNIST handwritten digit database. ATT Labs [Online]. Available: <http://yann.lecun.com/exdb/mnist>. Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv preprint arX:1708.07747.